260601-260605 每日总结汇总

260601 每日总结.md

260601 每日总结

前提

前几天的横评已经确认：DiffSBDD 的核心短板集中在成键、键长、原子类型分布和几何合理性上。今天的目标不是先改模型，而是先建立可靠的数据链和评价基线：如果 true bond / halfedge 数据本身不可靠，后续 bond predictor 或 edge diffusion 都没有意义。

干了什么

- 下载并预处理 CrossDocked pocket10 数据，建立 `processed_edge_noH_full` 数据缓存。
- 为 DiffSBDD 数据加载流程补充 `ligand_halfedge_index / ligand_halfedge_type`。
- 做 true-bond oracle reconstruction，验证真实键标签能否反构建分子。
- 做真实坐标下 OpenBabel / EDM / true-bond oracle 的成键消融。
- 做同批 DiffSBDD 生成点云的 OpenBabel vs EDM 重建质量对比。
- 将 molecule reconstruction 拆成可切换 backend，准备后续接 local / DiffGui / MolSnapper bond predictor。
- 构建 local bond predictor 的 train/val/test 数据报告。

结果与数据

CrossDocked 预处理

项	数值
原始 split	train `100000`, test `100`
自动 val	`300`
处理后 train	`99929`
val/test	`300 / 100`
18 核预处理耗时	约 `5分46秒`

项	数值
`train.npz`	约 `4.2G`
ligand atoms	`2,359,129`
directed bond entries	`5,063,798`

edge oracle 5000

指标	数值
samples	5000
oracle sanitize	`4334/5000`
total halfedges	`1,526,163`
total real bonds	`126,892`
no-bond fraction	`0.916856`
bad bond length rate	`0.7135%`

真实坐标重建消融 5000

method	sanitize	edge F1	bad bond length	fragments	解释
OpenBabel current	0.677	1.000	0.005	1.000	连边 pair 几乎对，但键阶/芳香语义有问题
EDM distance rule	0.917	0.984	0.001	1.521	sanitize 高但碎片多，missed bond 多
true-bond oracle	0.867	1.000	0.008	1.000	图结构上限，但缺 charge/H/aromatic semantic 会影响 sanitize

生成点云重建消融 500

method	sanitize	bad bond length	fragments	aromatic rings	seconds/mol
OpenBabel	0.746	0.177	1.288	0.284	0.0024
EDM	0.162	0.033	3.564	0.010	0.0016

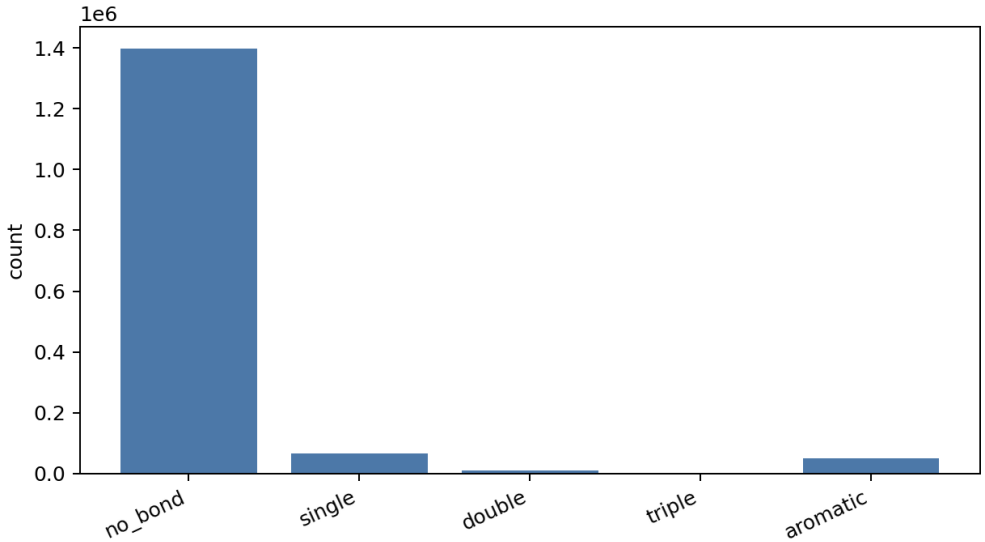
local bond predictor 数据链

split	analyzed	sanitize	bad length	no-bond	halfedge mismatch	bond mismatch
train	10000	0.8652	0.00726	0.9172	0	0
val	300	0.8767	0.00659	0.9154	0	0
test	100	0.8900	0.00581	0.9184	0	0

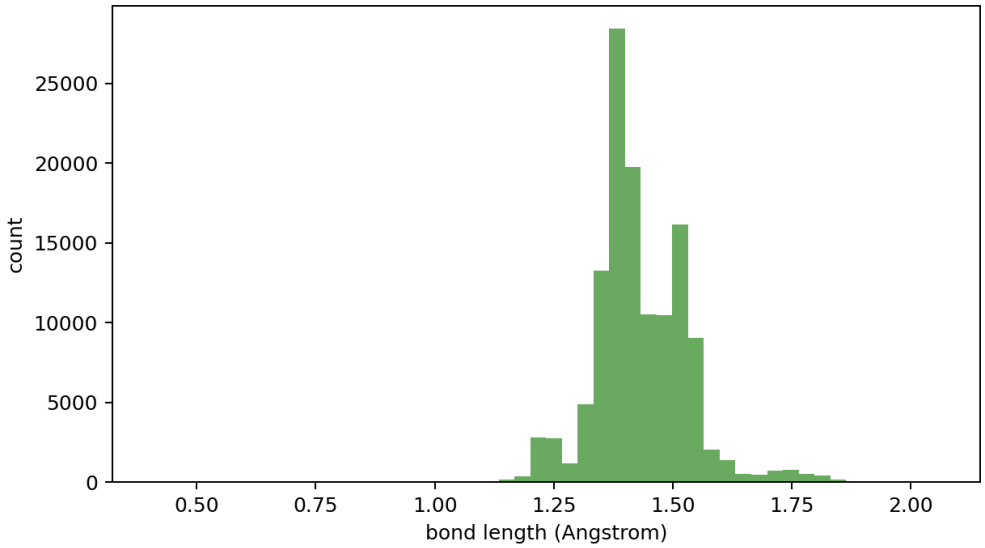
真实键型比例：single `52.38%`，double `8.21%`，triple `0.22%`，aromatic `39.19%`。

图表与文件

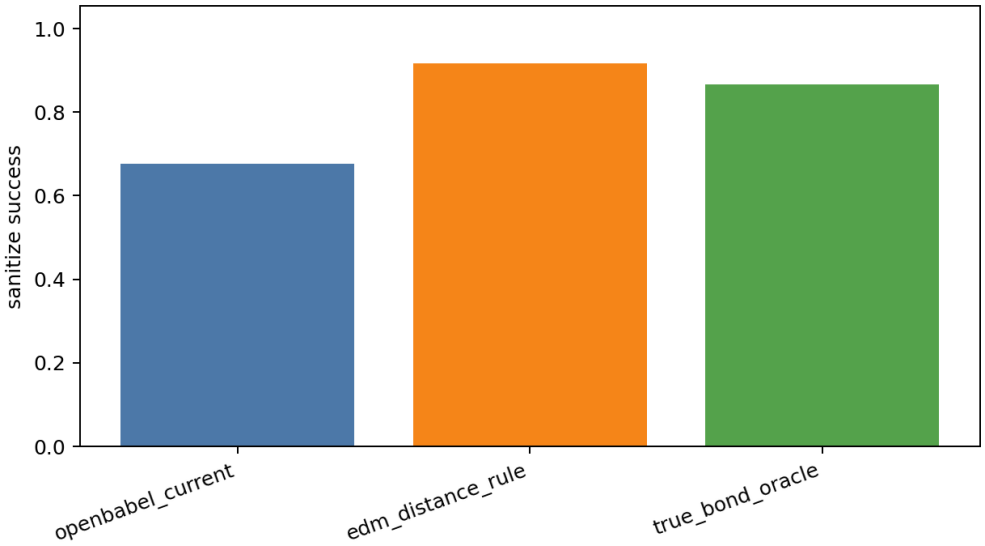
- CrossDocked 预处理日志：process_crossdock_18core.log
- edge oracle 报告：edge_data_oracle_report.md
- oracle bond type 图：



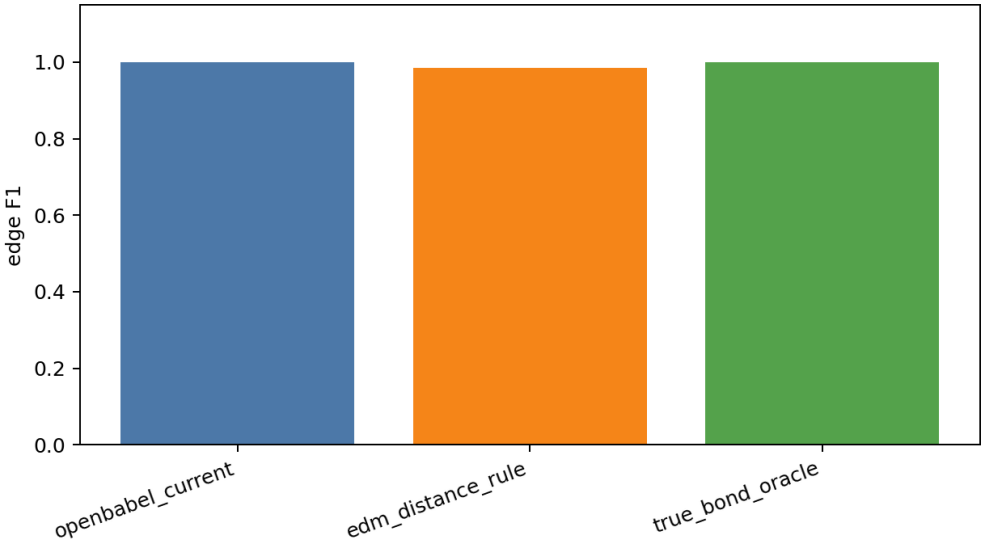
- oracle bond length 图：



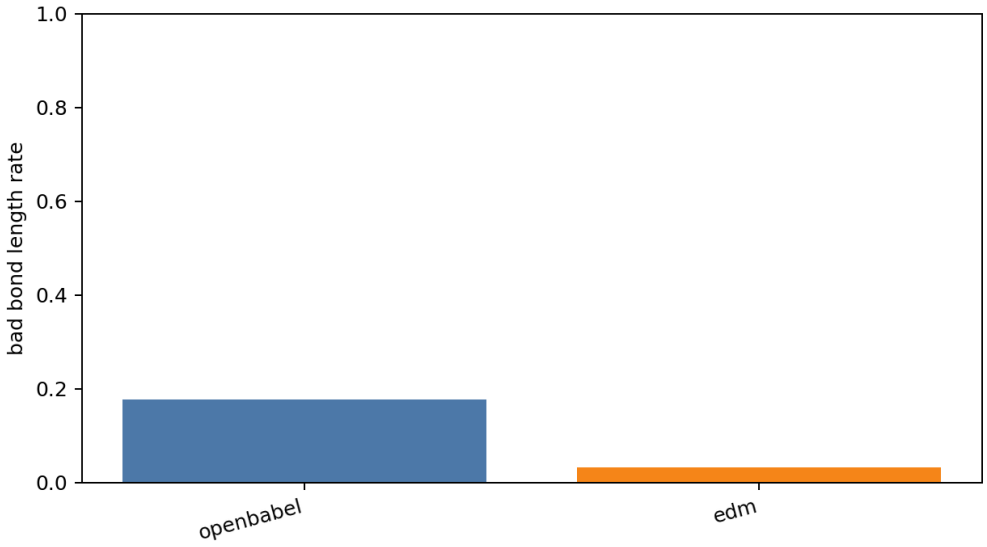
- 真实坐标重建消融：[reconstruction_ablation_report.md]
- sanitize 图：



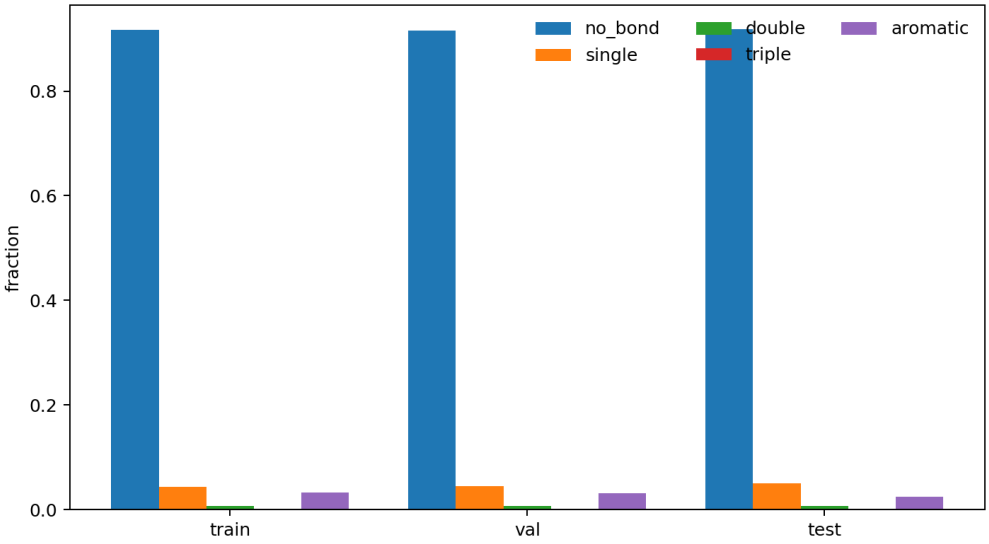
- edge F1 图：



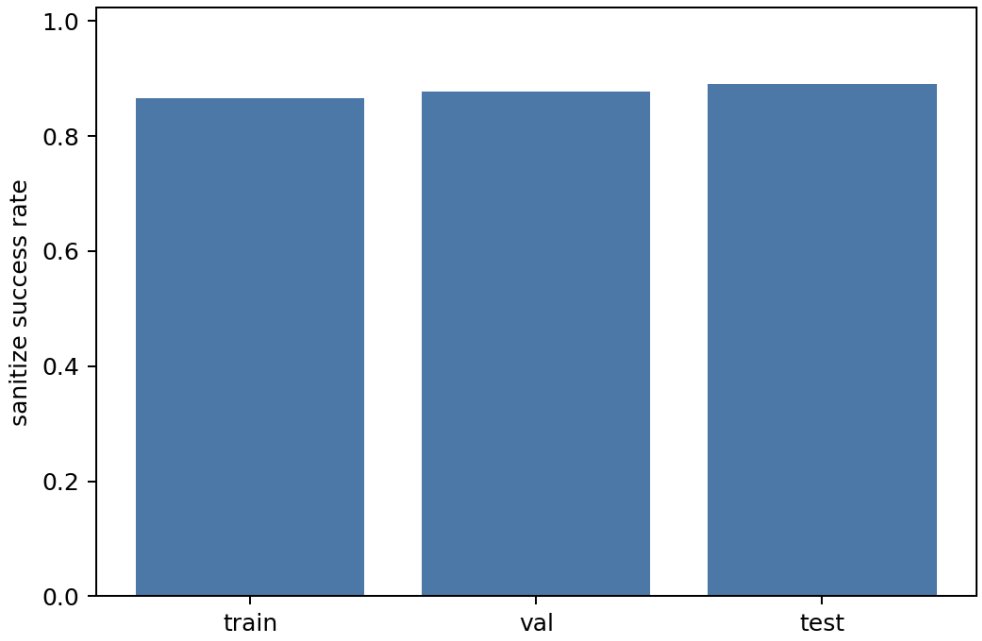
- 生成点云重建报告：generated_reconstruction_ablation_report.md
- 生成点云 bad bond 图：



- local predictor 数据报告：local_bond_predictor_data_report.md
- halfedge 类别图：



- oracle sanitize split 图：



- 当天记录目录：[work_records/26-6/260601]

分析结果

今天给出了后续 edge diffusion 的基础事实：

1. `halfedge_index/type` 数据链可靠，mismatch 为 0，可以作为训练目标。
2. no-bond 约 91.5%-91.8%，类别极不均衡，训练时必须给 no-bond 降权或使用 focal/分层策略。
3. OpenBabel 在真实坐标上 edge pair F1 高，但 sanitize 只有 0.677，说明主要错在键阶/芳香/价态语义，不是完全不会连边。
4. EDM 规则不能直接替代 OpenBabel，因为它在生成点云上造成大量碎片。
5. true-bond oracle sanitize 只有 0.867 不是数据链失败，而是 charge/H/aromatic/stereo 语义缺失，后续需要 semantic sidecar。

这一天的结论是：成键问题可以被拆成“数据标签、语义重建、预测器、decoder、扩散变量”几个解耦模块，不能一上来直接把 OpenBabel 换掉。

下一步

下一步应做 semantic-aware oracle reconstruction，补齐 charge/H/aromatic/stereo 语义，确认 true bond + true atom + true coordinate 能 100% 对齐原 SDF。然后再训练和评估 bond predictor。

260602 每日总结.md

260602 每日总结

前提

260601 已经证明 CrossDocked halfedge 数据链可靠，但也发现 oracle reconstruction 缺少语义字段、OpenBabel/EDM 各有明显缺陷。今天的目标是：一边尝试轻量改善 DiffSBDD 点云质量，一边把 edge/bond 数据链推进到可训练小闭环。

干了什么

- 训练本地 bond predictor v0，并把它接入 reconstruction benchmark。
- 做 clean CrossDocked / noise robustness / generated point cloud 的成键预测诊断。
- 实现 final-only geometry refine 与 atom prior/logits bias，并跑 1000 分子 GPU ablation。
- 实现 local atom mask，限制 F/Cl/Br/I 出现在不合理局部环境。
- 修复 oracle SDF 与 Schrodinger 兼容问题，生成 original vs repaired 配对 SDF。
- 构建 semantic-aware oracle reconstruction，用 sidecar 记录 charge/H/aromatic/stereo。
- 实现 edge denoiser 最小闭环，并升级为仿 DiffGui/MolSnapper 的 node-edge denoiser。

结果与数据

final-only geometry refine + atom bias，1000/group

group	sanitize	bad bond	3-rings/mol	QED	C fraction	sec/mol
baseline	0.968	0.343	1.474	0.419	0.661	0.492
atom_bias	0.939	0.385	1.460	0.371	0.651	0.492
geometry_refine	0.968	0.340	1.477	0.427	0.664	0.636
combined	0.942	0.384	1.453	0.375	0.656	0.652

atom bias 虽然降低 C fraction，但引入 P/Cl 等副作用，且 bad bond 和 QED 变差；geometry refine 当前强度太弱，基本不能改变主要质量指标。

local atom mask，1000/group

group	sanitize	bad bond	QED	3-rings/mol	F fraction
baseline	0.971	0.349	0.420	1.423	0.0535
local_mask	0.968	0.359	0.394	1.597	0.0148

local mask 能明显减少 F，但没有提高整体分子质量，不能默认进入主路径。

semantic-aware oracle

metric	default	semantic-aware	变化
no-stereo SMILES match	870/1000	1000/1000	+130
formal charge vector	989/1000	1000/1000	+11
aromatic atom vector	881/1000	1000/1000	+119
bond type map	881/1000	1000/1000	+119
repair none	870/1000	1000/1000	+130

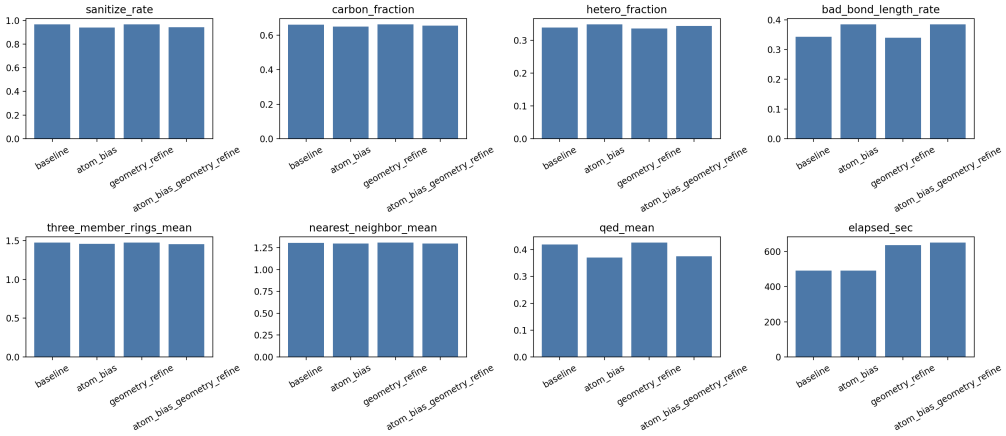
edge denoiser node-edge n32

metric	value
device	cuda
max molecules	32
epochs	80
final train_loss	0.004457
final eval_loss	0.025489
final accuracy	0.992624
final balanced_accuracy	0.922260
final real_bond_recall	0.909091
final no_bond_recall	1.000000

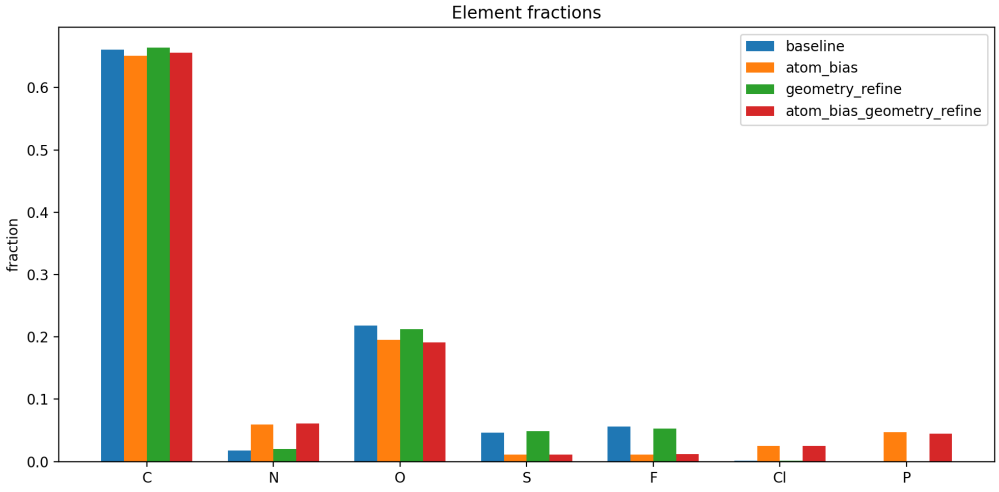
metric	value
recall_single	0.945607
recall_double	0.787879
recall_triple	1.000000
recall_aromatic	0.877814
best balanced_accuracy	0.955569

图表与文件

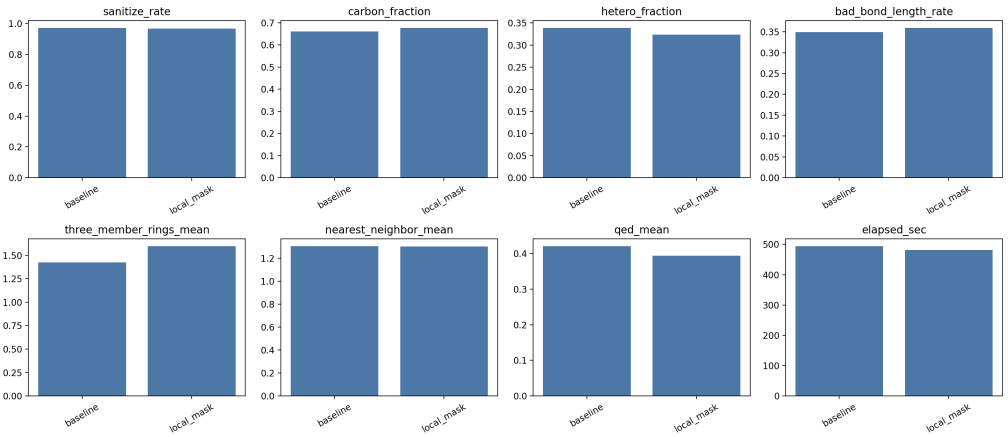
- final refine ablation CSV：metrics.csv
- final refine 质量图：



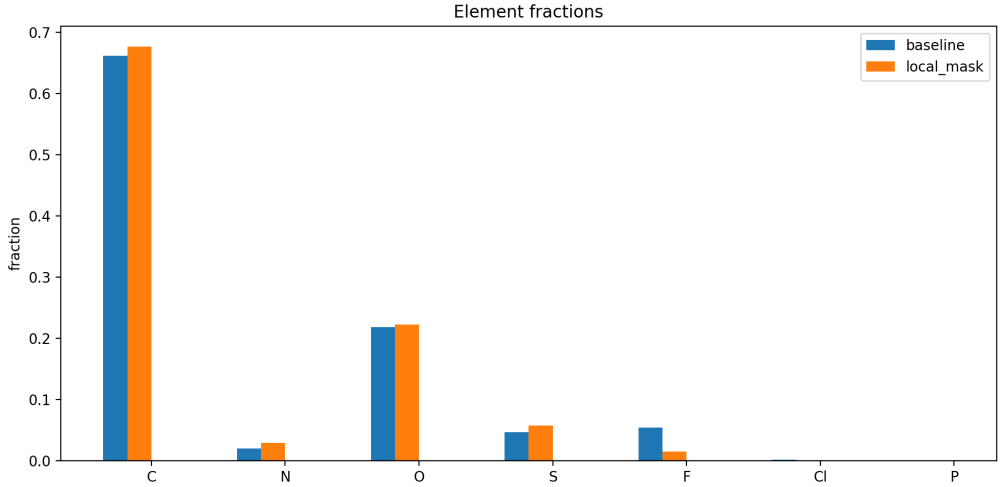
- final refine 元素图：



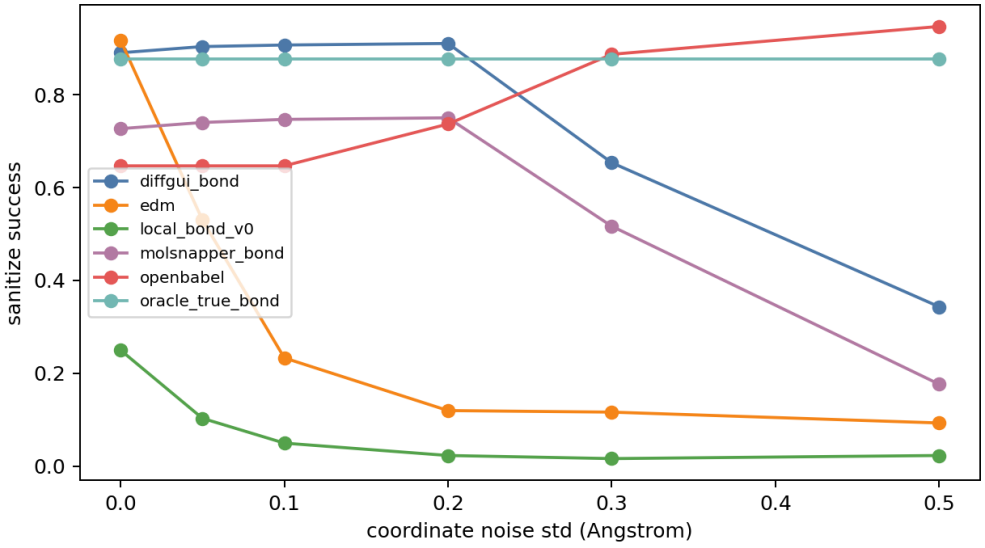
- local atom mask CSV：metrics.csv
- local atom mask 质量图：



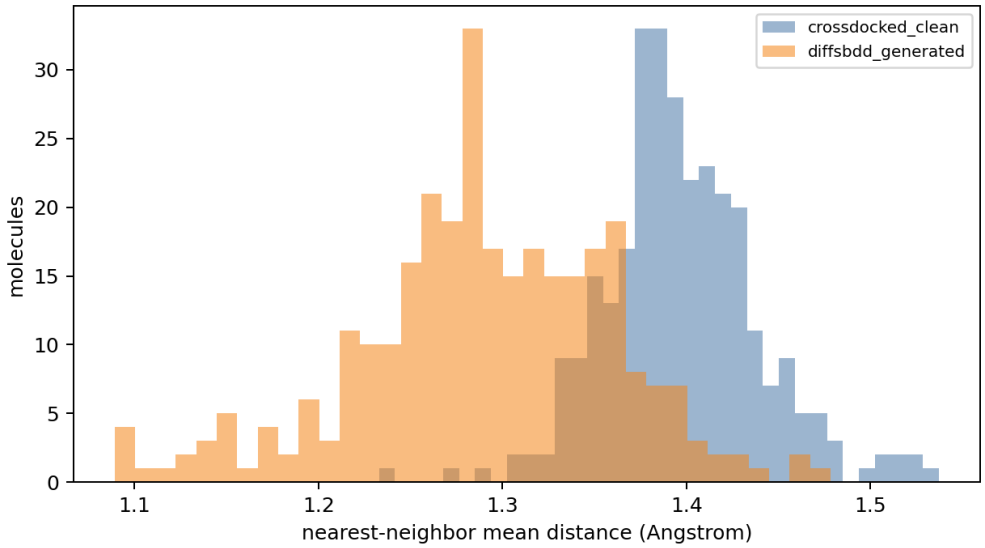
- local atom mask 元素图：



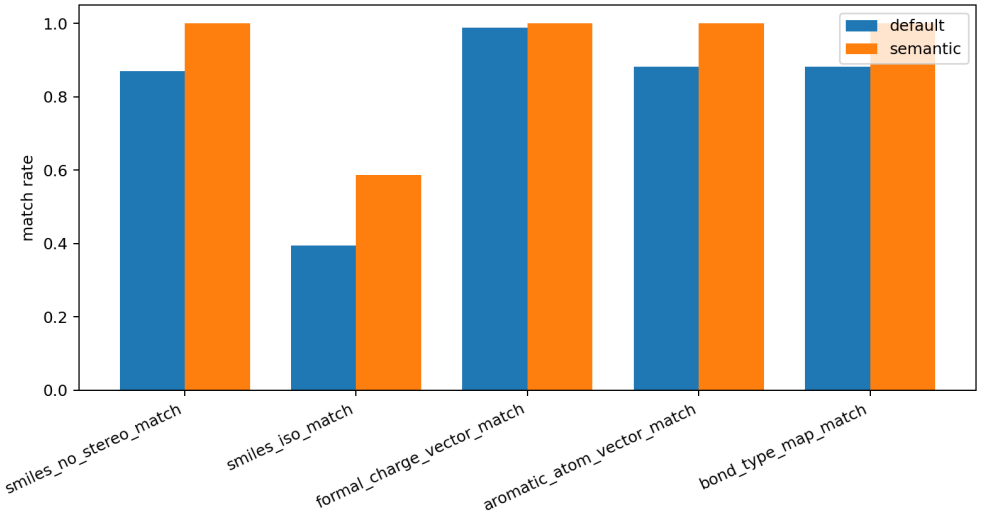
- bond predictor 诊断报告：[bond_predictor_diagnostics_report.md]
- noise sanitize 图：



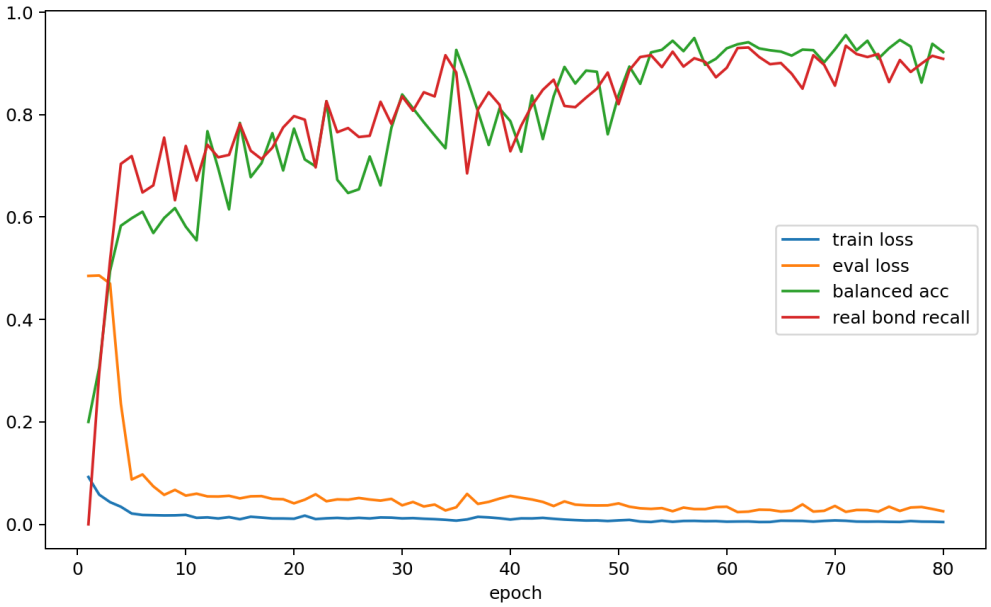
- generated geometry 图：



- semantic oracle 报告：[semantic_oracle_reconstruction_audit_report.md]
- semantic match 图：



- node-edge denoiser 报告：[edge_denoiser_overfit_report.md]
- node-edge 曲线：



- 当天记录目录：work_records/26-6/260602

分析结果

今天把两件事基本验证清楚：

1. 轻改里的 atom bias / final geometry refine / local atom mask 在当前参数下不能直接提高生成质量，只能保留为 ablation 工具。它们可以改变某些局部统计，但对 sanitize、三元环、bad bond 和 QED 没有正向证据。
2. edge 数据链是强信号。semantic-aware oracle 达到 100% 语义对齐，node-edge denoiser 在小样本上能学到真实键，说明“键预测任务本身可学”，不是数据链写错。

因此从今天开始，主线应从“后处理投机修补”转向“有监督 edge/bond 学习”，但仍要保持和普通 DiffSBDD + RL 解耦。

下一步

下一步应扩大 node-edge denoiser 到 1000 分子 train/val，加入 t 分层评估和 predicted-edge reconstruction，确认它不是单纯 overfit，也能在噪声时间步上恢复键。

260603 每日总结.md

260603 每日总结

前提

260602 已经证明 semantic oracle 和 node-edge edge denoiser 的小样本闭环可行，但还不知道泛化、t 噪声鲁棒性、重建质量，以及 DiffSBDD 与现代模型在 C1101 口袋上的真实差距。今天的目标是扩大验证，并做正式的同靶点多模型横评。

干了什么

- 将 node-edge edge denoiser 扩到 1000 分子 train/val。
- 做 t 分层评估、预测键重建和 C 组 edge denoiser ablation。
- 对 generated 点云做 edge denoiser 重建与苯环诊断。
- 重新跑 DiffSBDD 小改四组：baseline、atom prior/mask、geometry refine、combined。
- 构建 `x/h/e` edge diffusion 最小模型骨架并做小样本 overfit。
- 对 8GJL/C1101 口袋做 500 steps、500 分子、7 卡横评：先三模型，再扩展到六模型。

结果与数据

node-edge denoiser 1000 分子 train/val

metric	value
train / val molecules	800 / 200
wall time	约 180.8s
eval accuracy	0.994855
balanced accuracy	0.956287
real-bond recall	0.938899
recall_single	0.931624
recall_double	0.890661
recall_triple	1.000000

metric	value
recall_aromatic	0.959152

t 分层评估

t	accuracy	balanced acc	real-bond F1
0	0.9998	0.9968	0.9976
50	0.9995	0.9922	0.9935
100	0.9993	0.9909	0.9912
250	0.9982	0.9809	0.9788
500	0.9954	0.9613	0.9456
750	0.9926	0.9367	0.9121
950	0.9906	0.9217	0.8882
999	0.9902	0.9148	0.8837

DiffSBDD 轻改四组，1000/group, t=100

group	sanitize	bad bond	3-rings	benzene-like	C	N	O	QED
baseline	0.658	0.046	0.235	0.379	0.739	0.093	0.121	0.407
atom prior/ mask	0.656	0.047	0.241	0.375	0.740	0.098	0.130	0.392
geometry refine	0.658	0.046	0.234	0.377	0.739	0.093	0.121	0.406
combined	0.657	0.046	0.243	0.375	0.739	0.098	0.130	0.392

结论：当前轻改参数没有改善质量，不能默认进入生成路径。

x/h/e 小样本 overfit，n128 uniform prior

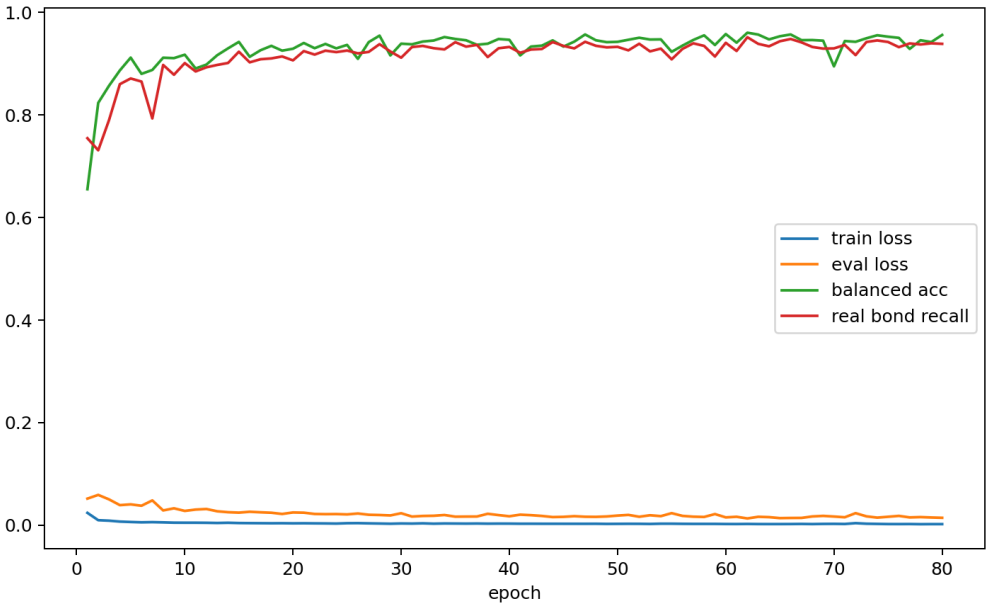
metric	value
eval edge accuracy	0.985316
real-bond F1	0.825392
atom accuracy	0.983535
pos RMSE	0.024327 Å
bond pair set match	1.000
bond type map match	0.125
semantic sanitize	0.563

六模型 8GJL/C1101 500 steps 横评

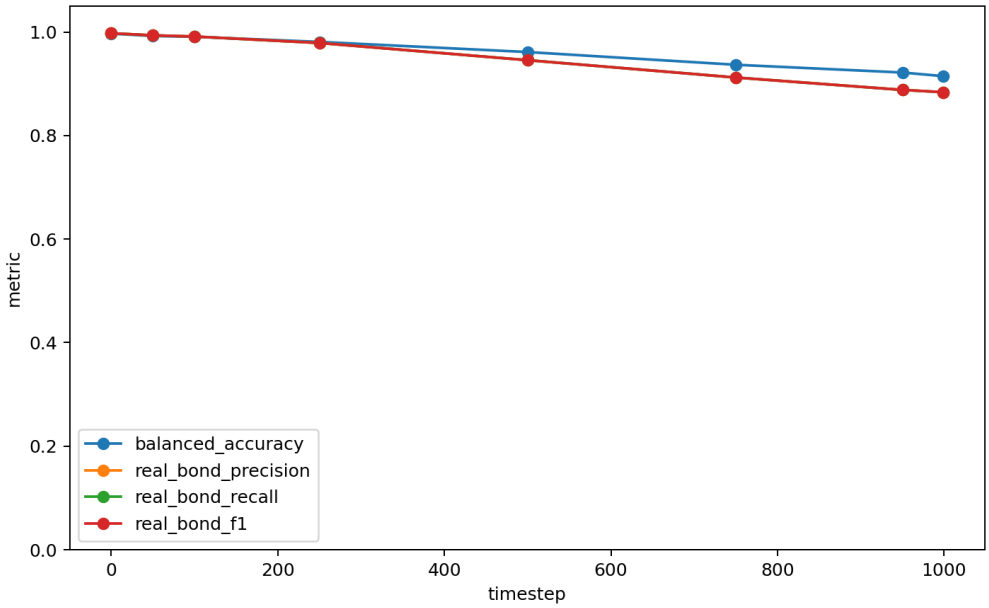
模型	wall s/mol	sanitize	unique valid	bad bond frac	aromatic mol rate	3-ring mol rate	QED
DiffSBDD	0.301	0.666	1.000	0.00287	0.412	0.154	0.604
DiffGui	13.268	1.000	0.996	0.000065	0.702	0.134	0.616
DePPA	0.323	0.982	1.000	0.00252	0.630	0.238	0.621
PMDM	1.606	1.000	0.406	0.00219	0.308	0.106	0.528
DiffInt	0.304	1.000	1.000	0.00000	0.402	0.355	0.609
DiffPharma	1.441	1.000	0.986	0.00000	0.479	0.772	0.655

图表与文件

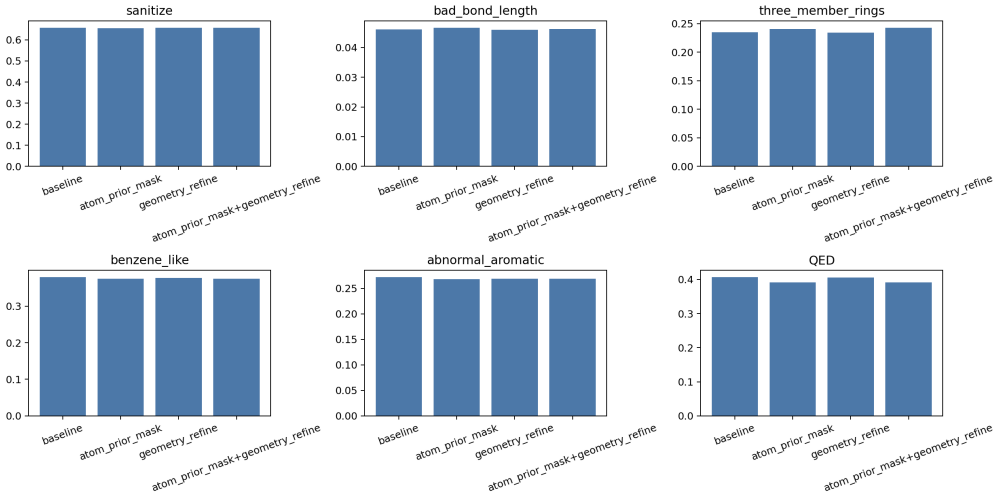
- edge denoiser 1000 曲线：



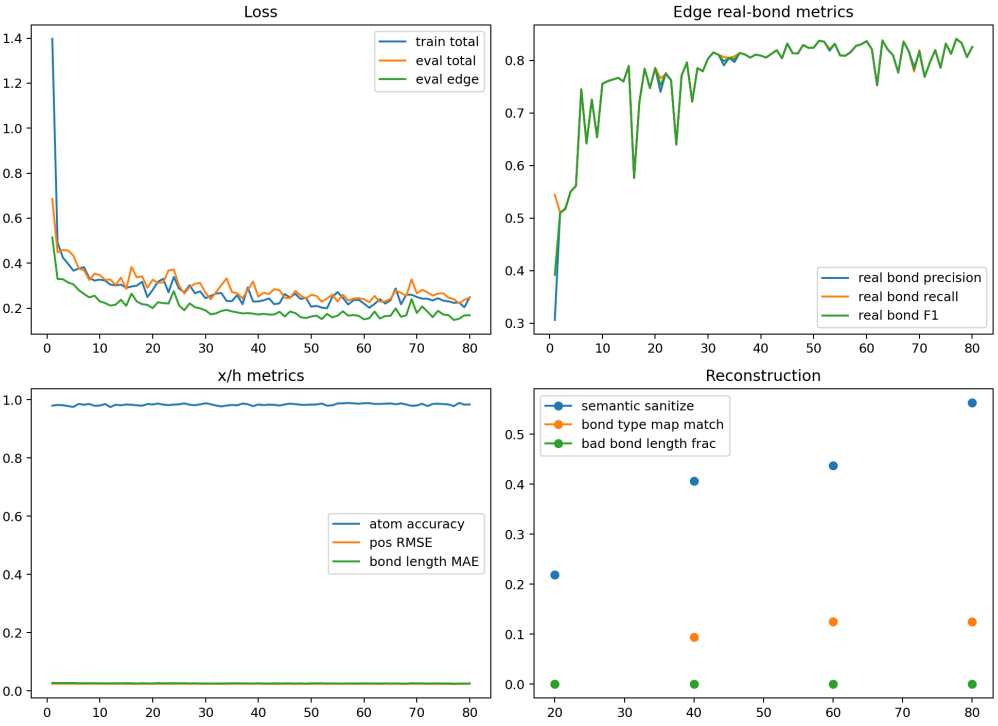
- t 分层报告：edge_denoiser_eval_report.md
- t 分层曲线：



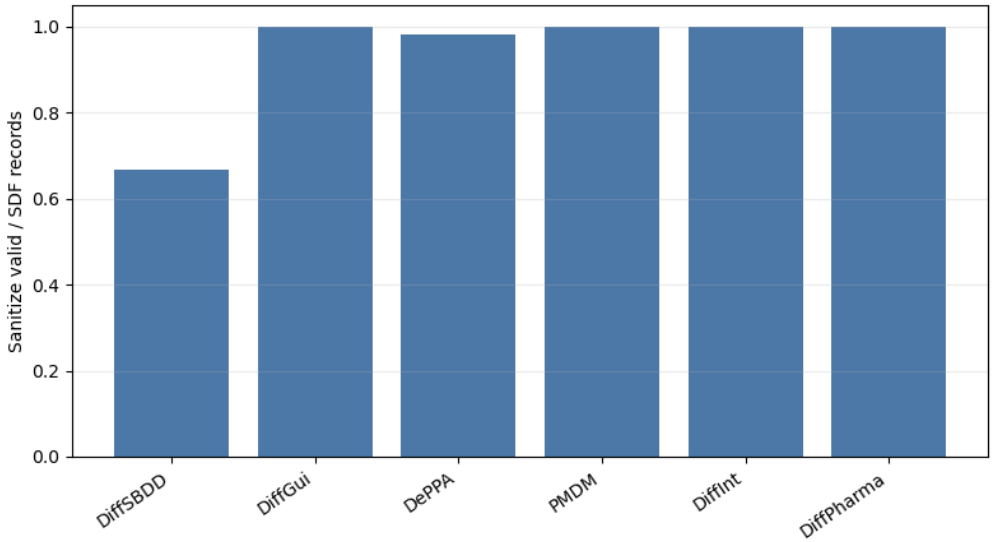
- 轻改报告：refinement_ablation_report.md
- 轻改质量图：



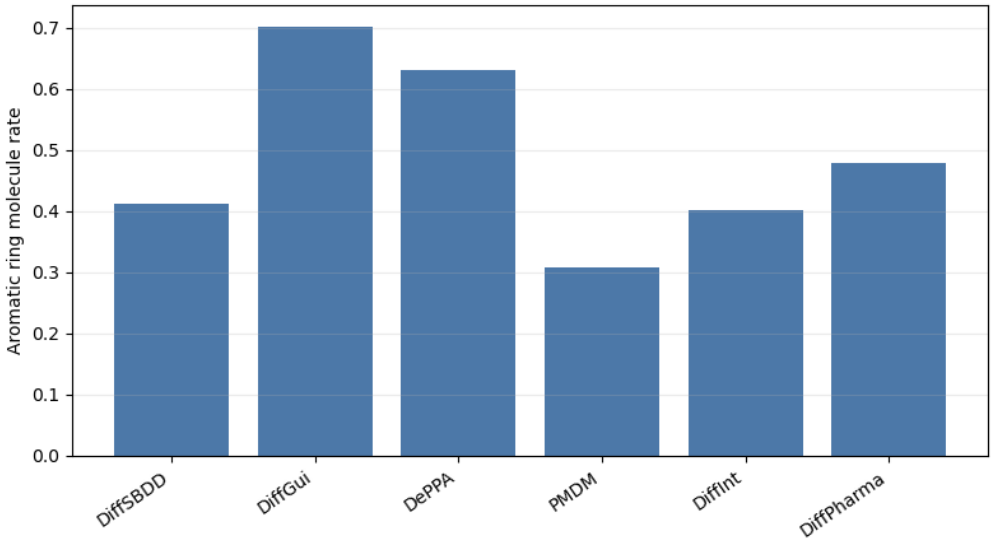
- xhe overfit 报告：[edge_diffusion_overfit_report.md]
- xhe overfit 曲线：



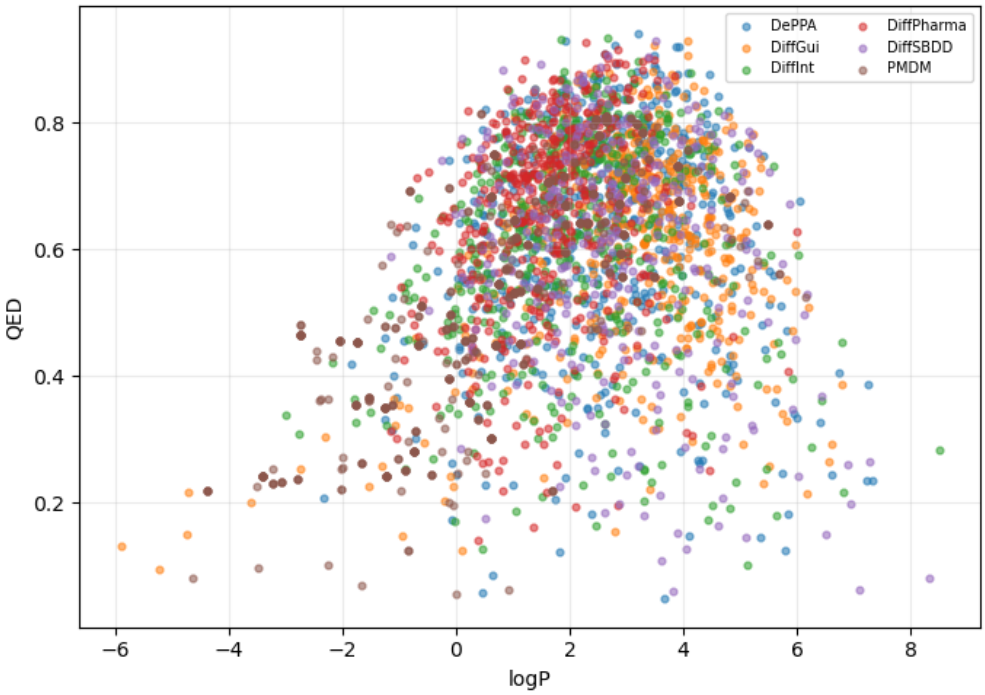
- 六模型 summary：[model_summary.csv]
- sanitize 图：



- aromatic 图：



- QED vs LogP 图：



- 当天记录目录：[work_records/26-6/260603]

分析结果

今天的结论非常明确：

1. node-edge edge denoiser 在 clean CrossDocked 坐标上不是玩具，1000 分子 train/val 能泛化，且 t=500 仍有 real-bond F1 0.946。
2. 但 edge denoiser 与完整生成还有距离：预测键重建的 exact halfedge / bond type 语义仍是瓶颈。
3. 小改线当前被阶段性证伪：atom prior/mask 和 geometry refine 参数不能改善 sanitize、bad bond、三元环和 QED。
4. 横评给出路线优先级：DiffGui 是质量上限但慢；DePPA 是速度和质量综合最现实参考；DiffSBDD docking 潜力不差但基础合法性弱；DiffInt/DiffPharma 的 interaction 思路可借，但三元环/碎片风险必须护栏。

下一步

下一步应补 docking 横评，把六模型生成质量和 UniDock 分数关联起来；同时把 x/h/e 分支从独立小模型推进到 DiffSBDD 主体内的可选 `diffusion_mode=xhe`。

260604 每日总结.md

260604 每日总结

前提

260603 横评显示 DiffSBDD 速度和 docking 潜力都还在，但 sanitize、芳香组织和结构合法性明显弱于 DiffGui/DePPA。今天一方面补 docking 证据，另一方面正式把项目拆成小改线、大改线、强化学习线，并推进 RL 的 KL/好分子池/化学护栏与 xhe 监督训练。

干了什么

- 对六模型 8GJL/C1101 输出做 UniDock fast docking 横评。
- 更新项目介绍文档为三条主线：小改、大改 xhe、强化学习。
- 分析近期 RL 高碳漂移和奖励稀疏问题。
- 对历史 KL 跳跃做诊断，并新增 `analytic_current_ref` 和 DePPA-style K3 模式。
- 设计/实现 ChemistryGuardReward、GoodMoleculePool 和磁盘 trajectory replay 方案。
- 审计 GoodMoleculePool 10 epoch 过滤效果。
- 实现 edge diffusion sampler smoke、多卡 DDP 训练入口和 DiffSBDD-xhe 字段传递/edge loss。
- 在 20k CrossDocked 子集上跑六卡 xhe 监督训练。

结果与数据

六模型 UniDock

模型	median	best 5% mean	<= -10	<= -12	positive count
DiffSBDD	-9.774	-12.770	0.450	0.044	4
DiffGui	-10.983	-14.055	0.720	0.250	0
DePPA	-9.645	-12.795	0.412	0.068	0
PMDM	-8.618	-11.336	0.188	0.002	0
DiffInt	-8.315	-11.171	0.108	0.004	0

模型	median	best 5% mean	<= -10	<= -12	positive count
DiffPharma	-8.416	-10.956	0.068	0.006	0

RL 高碳与奖励稀疏

指标	起点	末轮/最新	解释
carbon_fraction	0.6546	0.7937	明显高碳化
hetero_atom_mean	7.49	4.56	杂原子减少
TPSA	104.17	60.97	极性下降
classifier 正分占全部	-	9.71%	有效奖励稀疏
valid 内 docking<=-8 且 classifier>0	-	3.79%	可学习好样本很少
当前正式 KL	-	`kl_coef=0`	无预训练约束

KL / logprob 改造

模式	含义	状态
`analytic_ref_current`	旧版 KL(ref || current)	保留兼容
`analytic_current_ref`	新增 KL(current || ref)	推荐默认方向
`pretrained_logprob_k3`	DePPA/Schulman style K3 近似 KL	可选对照

验证：相关 pytest `19 passed`，`launch/smoke.sh` 通过。

GoodMoleculePool 10 epoch 审计

指标	数值
总生成	320
RDKit valid	199, 62.19%
manifest retained	16
final retained	16
通过所有 guard / 总分子	5.00%
通过所有 guard / valid	8.04%

指标	数值
retained score max	0.9007
retained score mean	0.1869
retained 中 score > 0	8/16
retained aromatic ring > 0	0/16

主要失败：three-member ring >0 为 66.83%，bad bond length >0.05 为 69.35%，carbon >0.85 为 21.61%。

DiffSBDD-xhe 20k 六卡监督训练

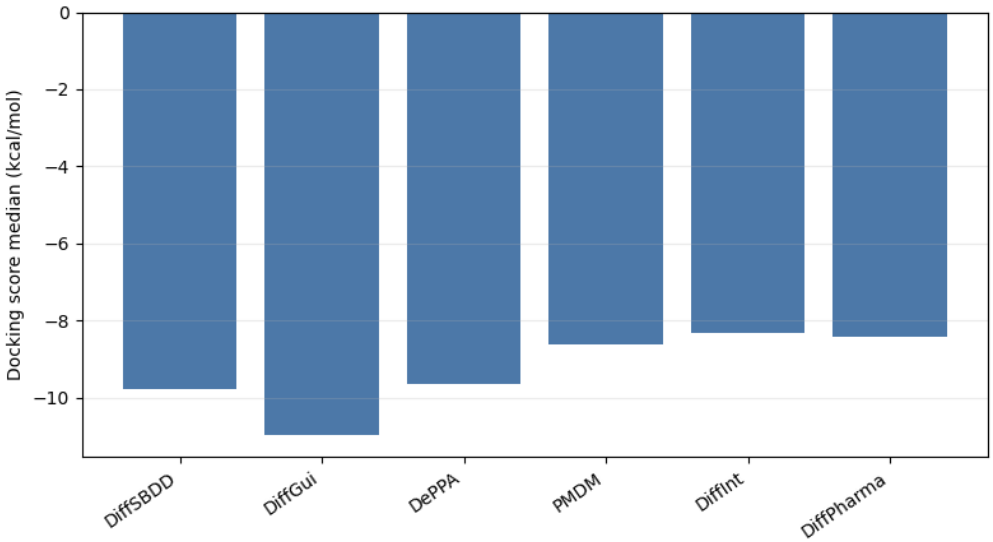
run	结果
`1epoch_b4`	成功，global_step 834
`3epoch_b4`	OOM，GPU3 已分配 9.20 GiB，再申请 68 MiB 失败
`3epoch_b2`	成功，耗时 1411.52s

验证集 edge 指标：

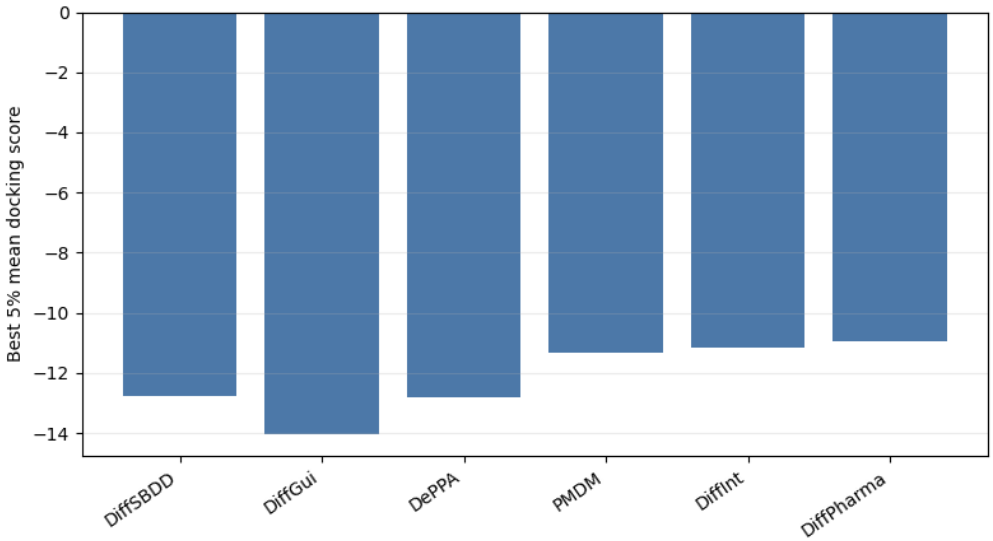
run	edge acc	real-bond acc	binary F1
baseline random edge	0.7073	0.0279	0.0657
1epoch_b4	0.8666	0.5915	0.5147
3epoch_b2_last	0.8855	0.5795	0.5417
3epoch_b2_best	0.8800	0.5766	0.5301

图表与文件

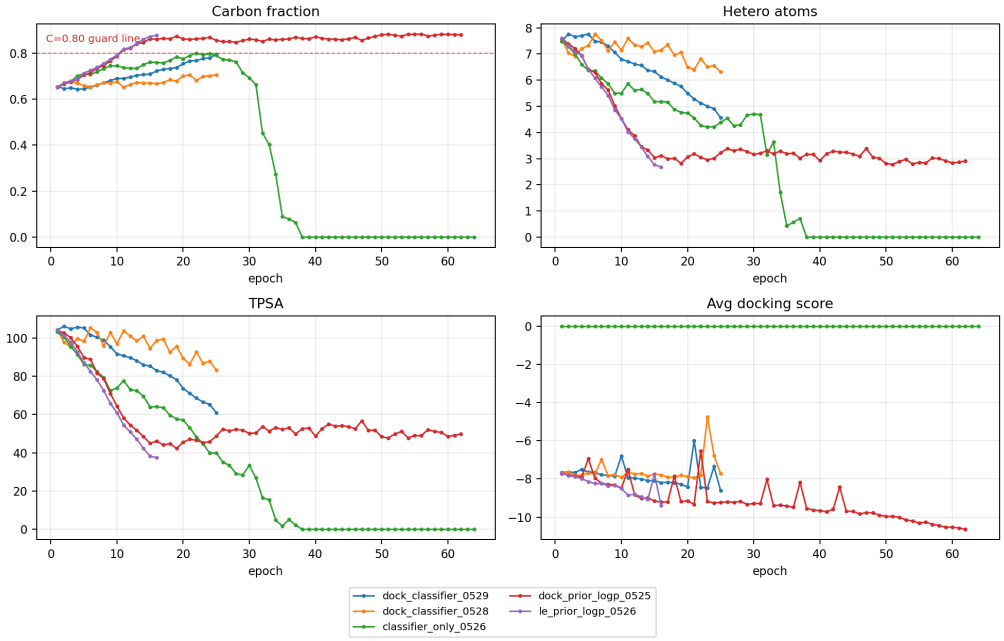
- UniDock summary：docking_model_summary.csv
- docking median 图：



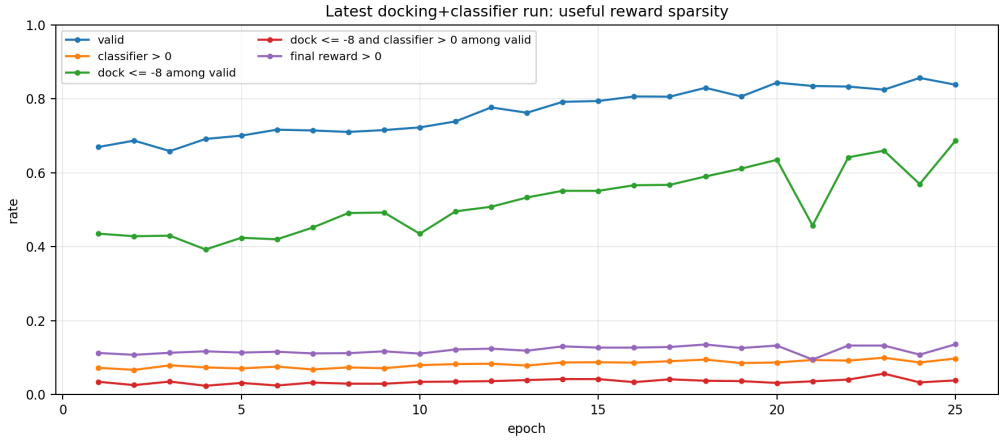
- best 5% 图：



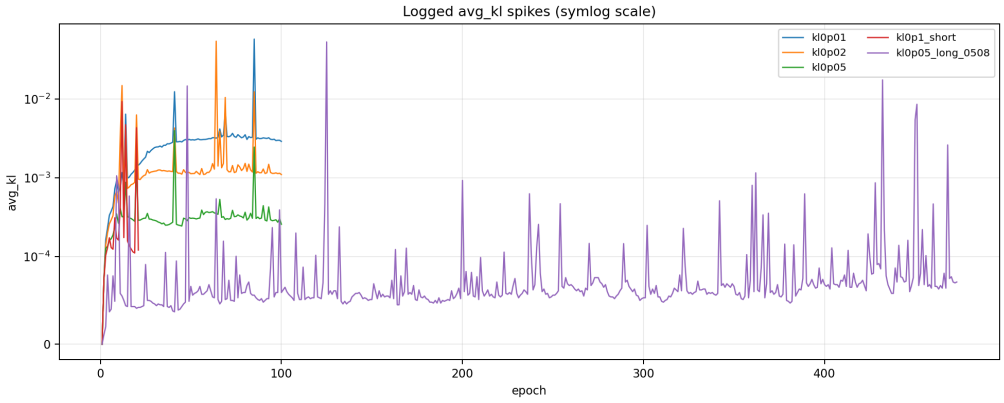
- RL 高碳报告：report.md
- descriptor 趋势图：



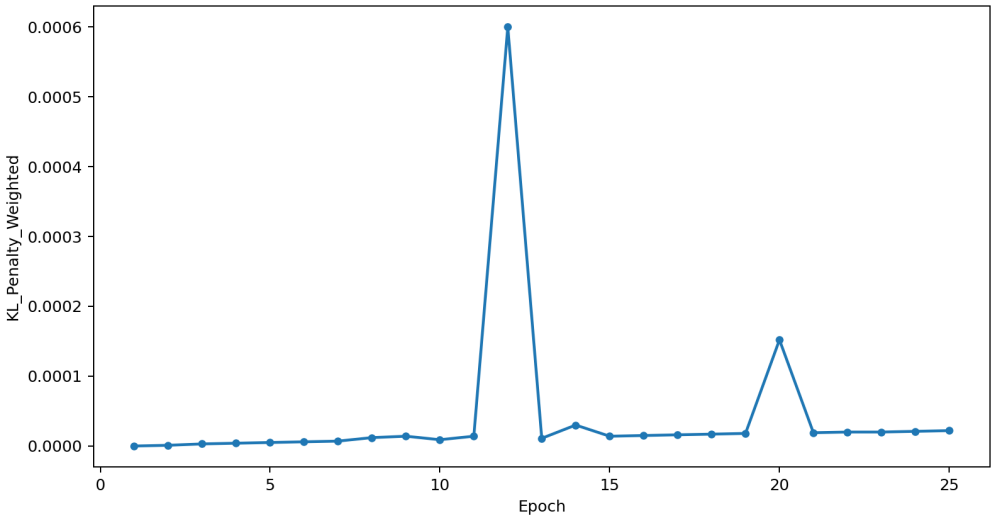
- reward 稀疏图：



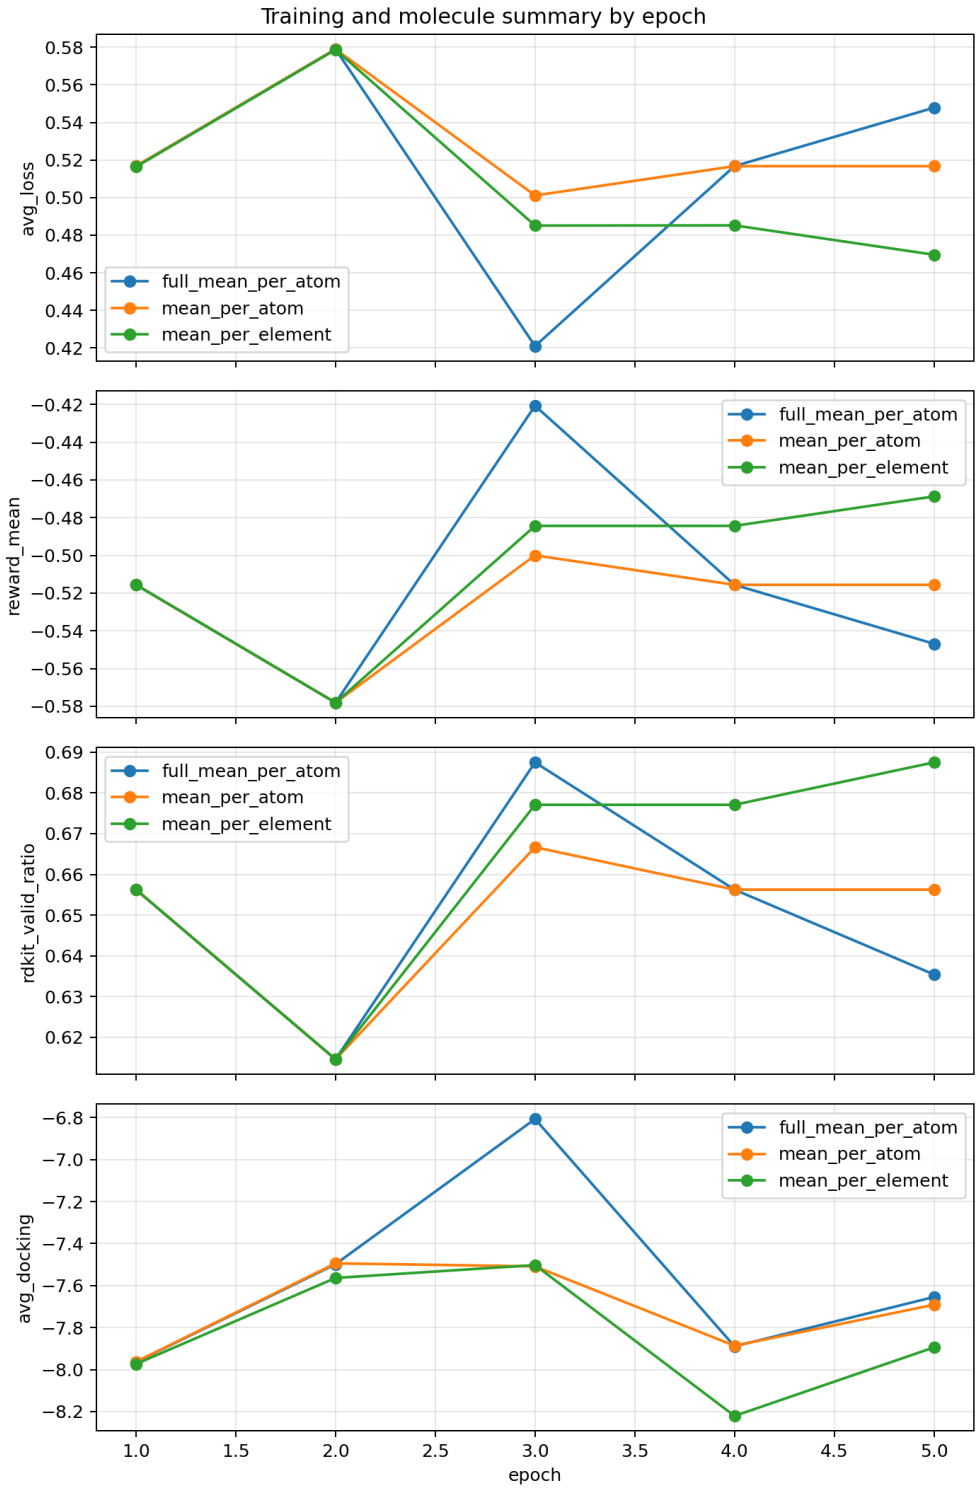
- KL 跳跃趋势：



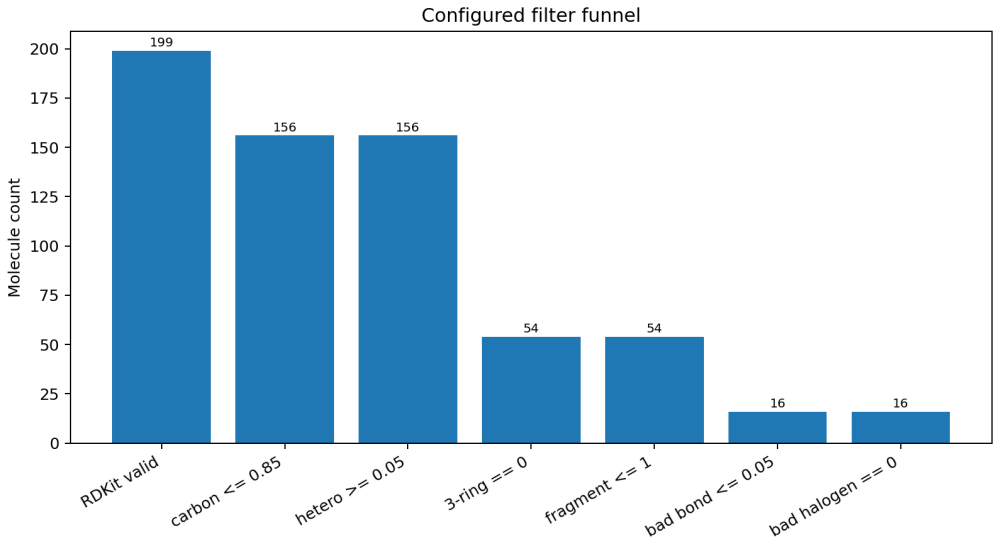
- KL0p02 趋势：



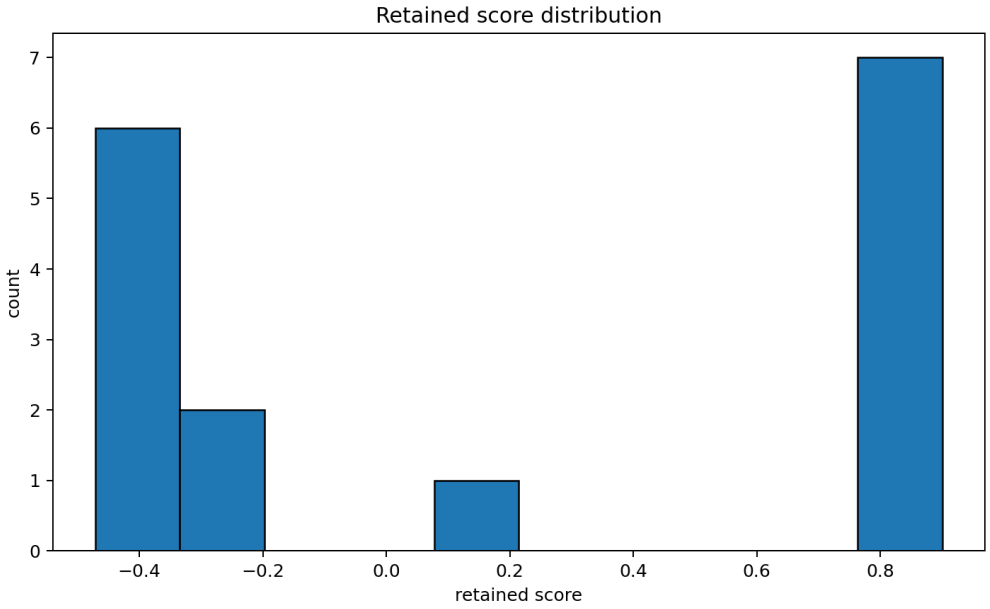
- logprob 模式实验图：



- GoodMoleculePool summary：summary.json
- GoodMoleculePool 漏斗：

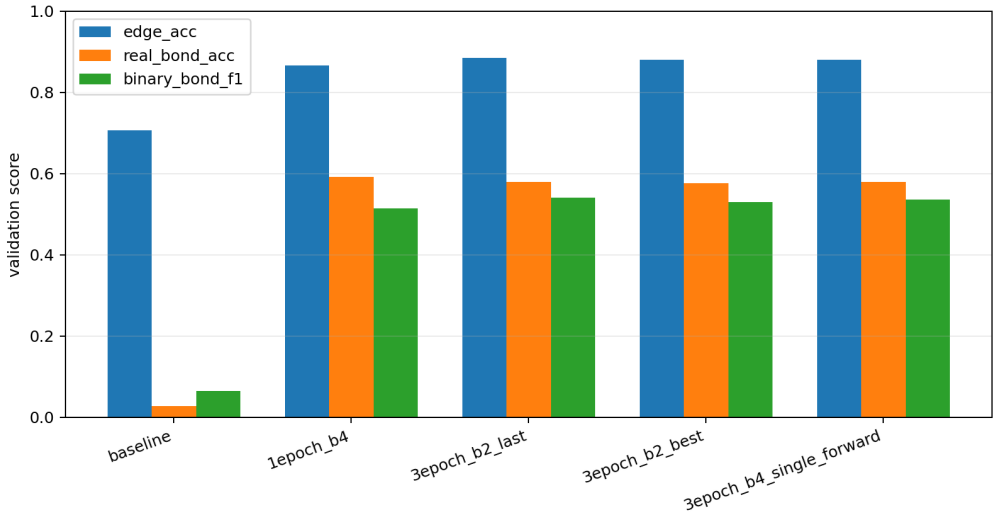


- retained 分数图：



- xhe 20k edge metrics：[combined_edge_metrics.csv]

- xhe val 指标图：



- 当天记录目录：work_records/26-6/260604

分析结果

今天有三个重要判断：

1. DiffSBDD docking 并没有完全崩。它 median -9.774，<= -10 比例 45%，说明当前底座有靶点优化潜力；真正短板是化学合法性和结构稳定性。
2. RL 线的核心问题是 reward 稀疏 + 缺少护栏 + KL 默认未启用。GoodMoleculePool 链路可用，但通过率很低，且 retained 分子没有芳香环，说明 pool 不能只看总分，必须加 ring/aromatic/geometry guard。
3. xhe 线已经证明 edge head 能从原 DiffSBDD checkpoint warm-start 后学到真实键信号；瓶颈从数据链变成工程显存和单次 denoiser 前向。

下一步

下一步应修 xhe 的双 EGNN 前向，改成一次 denoiser 同时输出 `x/h/e`；同时给正式训练增加本地 CSV 指标日志。RL 线则应用 `analytic_current_ref` 或 K3 做 KL 对照，并把 ChemistryGuardReward + GoodMoleculePool 作为解耦组件跑短 ablation。

260605 每日总结.md

260605 每日总结

前提

260604 的 xhe 监督训练说明 edge head 能学，但 batch4 多 epoch OOM，原因指向 `x/h` 和 `edge_forward_smoke` 双 EGNN 前向。今天的目标是把 xhe 线做成更接近真正 joint denoiser 的可训练版本，同时启动更正式的训练和显存安全测试。

干了什么

- 修复 DiffSBDD-xhe 单次 denoiser 前向：一次 dynamics 同时输出 `net_out_lig/net_out_pocket/edge_logits`。
- 做 predicted-edge reconstruction smoke，测试训练后的 edge head 能否反构建 RDKit 分子。
- 加入 xhe 联合消息传递和采样接口，让 `e_t` embedding 进入 EGNN message passing。
- 整理 xhe 训练结果和与原始 DiffSBDD 的公平对照设计。
- 从原始 DiffSBDD checkpoint warm-start 启动全量 xhe 训练。
- 构建 `pocket1000` 和 `pocket750` capped CrossDocked edge 缓存，控制 outlier pocket OOM。
- 实现本地 CSVLogger 和训练进度打印规则。
- 测试 pocket750 下 b4acc2 / b8acc1 显存安全性。

结果与数据

单次 denoiser 前向修复

测试	修复前	修复后
batch4 / 3epoch / 6GPU	OOM, 205.71s	成功, 495.42s
global_step	未完成	2502
checkpoint	无完成 ckpt	`last.ckpt`, best epoch 0

验证集 edge 指标：

run	edge acc	real-bond acc	binary F1
baseline random edge	0.7073	0.0279	0.0657
old batch2 / 3epoch	0.8855	0.5795	0.5417
new batch4 / 3epoch single-forward	0.8806	0.5802	0.5366

predicted-edge reconstruction

timestep	sanitize	SMILES match	bond pair F1	halfedge acc	bad bond length	pred bonds	target bonds	3-ring
0	1.0000	1.0000	1.0000	1.0000	0.0002	24.997	24.997	0.033
10	0.9967	0.9900	1.0000	0.9999	0.0002	24.997	24.997	0.033
50	0.8233	0.6033	0.9946	0.9966	0.0099	25.227	24.997	0.143
100	0.2733	0.0367	0.9394	0.9776	0.1075	27.880	24.997	0.497
250	0.0000	0.0000	0.5349	0.8007	0.6130	57.193	24.997	0.000
500	0.7267	0.0000	0.0703	0.7769	0.3029	10.853	24.997	0.010

joint 20k / 6GPU / 5 epoch

项	数值
train / val	20000 / 300
GPU	6
batch size	1
accumulate grad	4
epoch	5
耗时	2021.82s，约 33.7min
原始 DiffSBDD checkpoint	epoch 999, global_step 1,562,000

edge val：

model	edge acc	real-bond acc	binary F1
warm_start_random_edge	0.3835	0.4893	0.1976
joint_20k_b1acc4_5ep_last	0.8948	0.5369	0.5568

pocket capped 数据

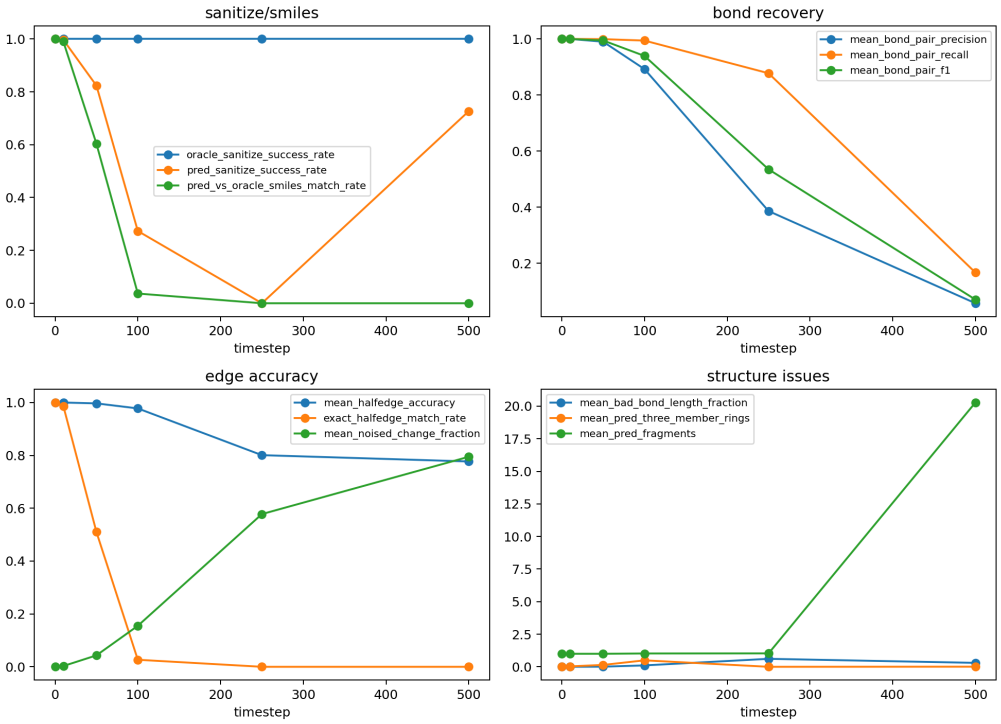
cache	train kept	train removed	val kept	kept pocket max	kept total max
pocket1000	99504/99929	425, 0.425%	300/300	999	1052
pocket750	98501/99929	1428, 1.43%	296/300	750	791

pocket750 batch 显存测试

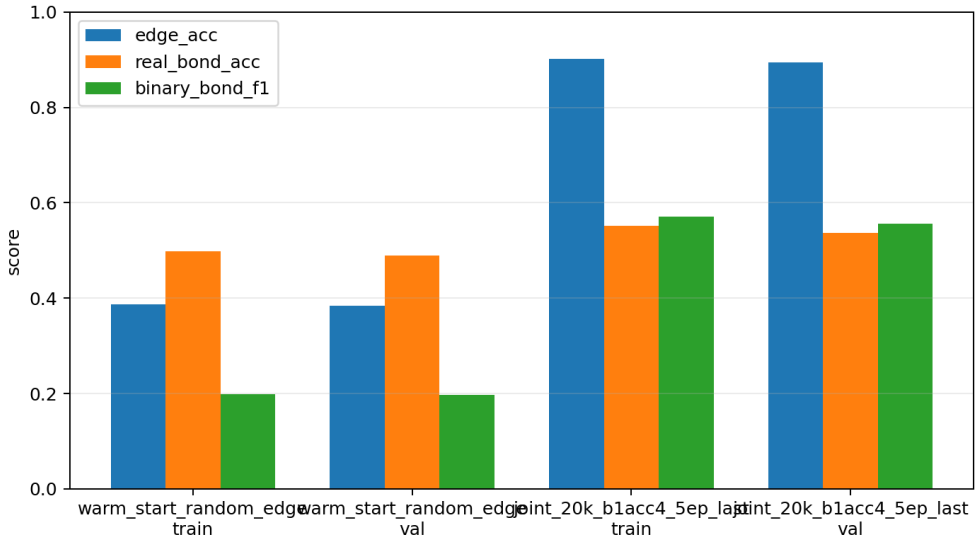
配置	是否能跑	峰值观察	结论
b4acc2	完整 1 epoch	9809/10240 MB	能跑但几乎无余量，不推荐长训
b8acc1	启动并跑过 100 batch	9793/10240 MB	显存贴满，手动停止，不推荐
b2acc4	未在本记录重跑	预计更安全	推荐 50 epoch 默认

图表与文件

- single-forward xhe 记录：260605-01
- predicted-edge reconstruction 记录：260605-02
- predicted reconstruction 报告：predicted_edge_reconstruction_report.md
- predicted reconstruction 图：



- xhe joint edge metrics：edge_metrics_summary.csv
- xhe edge bars：



- pocket1000 split summary：split_summary.csv
- pocket750 split summary：split_summary.csv
- pocket750 memtest log：train_xhe_from_original_10class_full_pocket750_8gpu_b4acc2_memtest_1ep.log
- b2acc4 metrics CSV：metrics.csv
- 当天记录目录：work_records/26-6/260605

分析结果

今天的核心结论是：

1. xhe OOM 的主要原因已经定位并修复：双 EGNN 前向改成单次 forward 后，batch4/3epoch 能跑完，edge 指标没有明显变差。
2. 当前 xhe 还不是成熟完整 edge diffusion。低噪声 `t=0/10/50` 能很好修边，但高噪声 `t=100/250/500` 仍会多连键、少连键或碎片化，说明需要真正的 `e_t -> e_{t-1}` sampler、更长训练和 t 分层 loss。
3. pocket graph 大小是显存关键因素。pocket1000 删除样本极少但仍有大图压力；pocket750 删除 1.43% train 样本，最大 total nodes 降到 791，更适合 10GB 卡。
4. b4/b8 per-GPU batch 在 10GB RTX 3080 上不安全，正式长训应选 `pocket750 b2acc4` 或继续压缩 pocket/edge graph，而不是盲目加 batch。
5. 本地日志规则已补上，后续正式训练必须有 `metrics/metrics.csv` 和 rank-0 进度输出，不能依赖 WandB。

下一步

下一步最稳的正式训练方案是从原始 DiffSBDD checkpoint warm-start，用 `pocket750 batch_size=2 accumulate_grad_batches=4` 跑 50 epoch，保留 5 epoch checkpoint 和 best checkpoint；同时开发真正的 edge sampler，并在验证集上持续看 edge acc、real-bond acc、sanitize、predicted-edge reconstruction，而不是只看 loss。